

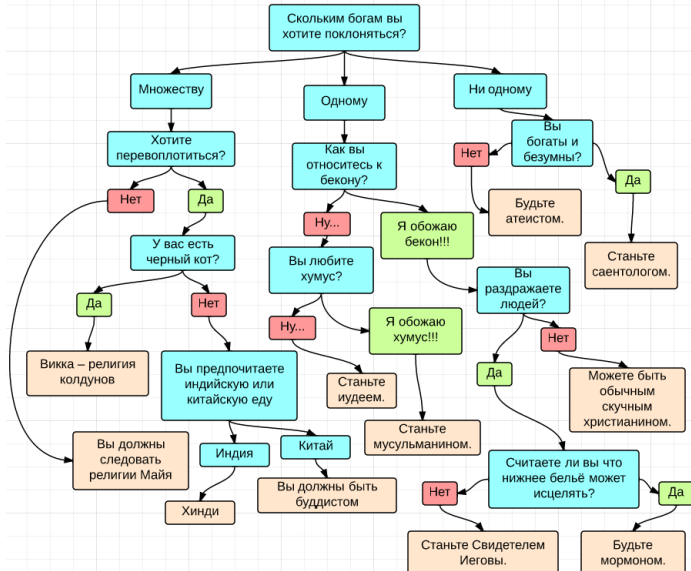
Введение в искусственный интеллект.
Машинное обучение
Лекция 8. Решающие деревья. Случайный лес

MaTIC

12 апреля 2019г.

- ❶ Случайные деревья
 - ID3 (Iterative Dichotomiser 3)
 - CART (Classification And Regression Tree)
- ❷ Случайный лес

Примеры деревьев из жизни



Примеры деревьев из жизни



Скрипт разговора оператора



- Инструкции любого call-центра

Примеры деревьев из жизни

- Инструкции любого call-центра
- Постановка медицинского диагноза

Примеры деревьев из жизни

- Инструкции любого call-центра
- Постановка медицинского диагноза
- Многие алгоритмы имеют древовидную структуру

Примеры деревьев из жизни

- Инструкции любого call-центра
- Постановка медицинского диагноза
- Многие алгоритмы имеют древовидную структуру

Достоинства

Главные достоинства дерева — интерпретируемость и простота

Определение



Решающее дерево — алгоритм машинного обучения, задающийся деревом со следующими свойствами:

- 1 Выделена вершина — корень дерева
- 2 Листовой вершине (у которой нет потомков) соответствует некоторый ответ алгоритма $y \in Y$
- 3 Каждой внутренней вершине соответствует предикат. Каждому ребру из внутренней вершины соответствует некоторое значение предиката


Пример решающего дерева для задачи классификации

Ирисы Фишера

Задача Фишера о классификации цветков ириса на 3 класса



Пример решающего дерева для задачи регрессии



Часто используемые виды предикатов

- Пороговое условие

Часто используемые виды предикатов

- Пороговое условие
- Конъюнкция пороговых условий

Часто используемые виды предикатов

- Пороговое условие
- Конъюнкция пороговых условий
- Синдром — выполнение какого-то минимального количества условий

Часто используемые виды предикатов

- Пороговое условие
- Конъюнкция пороговых условий
- Синдром — выполнение какого-то минимального количества условий
- Полуплоскость — линейная пороговая функция


Часто используемые виды предикатов

- Пороговое условие
- Конъюнкция пороговых условий
- Синдром — выполнение какого-то минимального количества условий
- Полуплоскость — линейная пороговая функция
- Шар — пороговая функция близости

Критерии информативности критерия для задачи двухклассовой классификации

Пусть p — частота встречаемости одного из классов

Ошибка классификации	$1 - \max(p, 1 - p)$
Индекс Джинни	$2p(1 - p)$
Кросс-энтропийный критерий	$-p \log p - (1-p) \log(1-p)$




- Критерии довольно похоже
- Последние два критерия — дифференцируемые

Критерии информативности критерия для задачи двухклассовой классификации

Пусть p — частота встречаемости одного из классов

Ошибка классификации	$1 - \max(p, 1 - p)$
Индекс Джинни	$2p(1 - p)$
Кросс-энтропийный критерий	$-p \log p - (1-p) \log(1-p)$



- Критерии довольно похоже
- Последние два критерия — дифференцируемые
- Есть по 400 наблюдений из двух классов. Вопрос какое разделение лучше (300, 100) и (100, 300) против (200, 400) и (200, 0)?

Критерии информативности критерия для задачи многоклассовой классификации

Определения

Пусть R_m — некоторая часть пространства, содержащая N_m объектов.

Пусть $\hat{p}_{mk} = \frac{1}{N_m} \sum_{x_i \in R_m} [y_i = k]$.

$k(m) = \arg \max_k \hat{p}_{mk}$ — мажоритарный класс

Ошибка классификации	$\frac{1}{N_m} \sum_{i: x_i \in R_m} [y_i \neq k(m)] = 1 - \hat{p}_{mk(m)}$
Индекс Джинни	$\sum_{k \neq k'} \hat{p}_{mk} \hat{p}_{mk'} = \sum_k \hat{p}_{mk} (1 - \hat{p}_{mk})$
Кросс-энтропийный критерий	$-\sum_k \hat{p}_{mk} \log \hat{p}_{mk}$

Вход: U — обучающая выборка; \mathcal{B} — множество элементарных предикатов;**Выход:**возвращает корневую вершину дерева, построенного по выборке U ;

- 1: **ПРОЦЕДУРА** LearnID3(U);
- 2: **если** все объекты из U лежат в одном классе $c \in Y$ **то**
- 3: создать новый лист v ;
- 4: $c_v := c$;
- 5: **вернуть** (v);
- 6: найти предикат с максимальной информативностью:
 $\beta := \arg \max_{\beta \in \mathcal{B}} I(\beta, U)$;
- 7: разбить выборку на две части $U = U_0 \cup U_1$ по предикату β :
 $U_0 := \{x \in U : \beta(x) = 0\}$;
 $U_1 := \{x \in U : \beta(x) = 1\}$;
- 8: **если** $U_0 = \emptyset$ или $U_1 = \emptyset$ **то**
- 9: создать новый лист v ;
- 10: $c_v :=$ класс, в котором находится большинство объектов из U ;
- 11: **иначе**
- 12: создать новую внутреннюю вершину v ;
- 13: $\beta_v := \beta$;
- 14: $L_v := \text{LearnID3}(U_0)$; (построить левое поддерево)
- 15: $R_v := \text{LearnID3}(U_1)$; (построить правое поддерево)
- 16: **вернуть** (v);

¹<http://www.machinelearning.ru/wiki/images/3/3e/Voron-ML-Logic.pdf>

Преимущества

Преимущества

- Простота реализации

Преимущества

- Простота реализации
- Хорошая интерпретируемость

Преимущества

- Простота реализации
- Хорошая интерпретируемость
- Сложность алгоритма линейна по длине выборки

Преимущества

- Простота реализации
- Хорошая интерпретируемость
- Сложность алгоритма линейна по длине выборки
- Алгоритм легко поддаётся многочисленным усовершенствованиям

Преимущества и недостатки алгоритма ID3

Преимущества

- Простота реализации
- Хорошая интерпретируемость
- Сложность алгоритма линейна по длине выборки
- Алгоритм легко поддаётся многочисленным усовершенствованиям

Недостатки

- Жадность. Локальный выбор оптимального предиката не является глобальным

Преимущества и недостатки алгоритма ID3

Преимущества

- Простота реализации
- Хорошая интерпретируемость
- Сложность алгоритма линейна по длине выборки
- Алгоритм легко поддаётся многочисленным усовершенствованиям

Недостатки

- Жадность. Локальный выбор оптимального предиката не является глобальным
- Большая вариация алгоритма, при небольших изменениях в данных структура дерева полностью меняется

Преимущества и недостатки алгоритма ID3


Преимущества

- Простота реализации
- Хорошая интерпретируемость
- Сложность алгоритма линейна по длине выборки
- Алгоритм легко поддаётся многочисленным усовершенствованиям



Недостатки

- Жадность. Локальный выбор оптимального предиката не является глобальным
- Большая вариация алгоритма, при небольших изменениях в данных структура дерева полностью меняется
- Алгоритм склонен к переобучения, так как усложняет структуру дерева




Алгоритм построения дерева для регрессии



Алгоритм построения дерева для регрессии






Алгоритм построения дерева для регрессии



$$f(x) = \sum_{m=1}^M c_m I(x \in R_m)$$

Алгоритм построения дерева для регрессии



$$f(x) = \sum_{m=1}^M c_m I(x \in R_m)$$
$$c_m = \text{ave}(y_i | x_i \in R_m)$$

Алгоритм построения дерева для регрессии

$$f(x) = \sum_{m=1}^M c_m I(x \in R_m)$$
$$c_m = \text{ave}(y_i | x_i \in R_m)$$

Ветвление

Пусть $R_1(j, s) = \{X | X_j \leq s\}$ и $R_2(j, s) = \{X | X_j > s\}$

Тогда на каждом шаге будем решать задачу минимизации

$$\min_{j,s} \left(\min_{c_1} \sum_{x_i \in R_1(j,s)} (y_i - c_1)^2 + \min_{c_2} \sum_{x_i \in R_2(j,s)} (y_i - c_2)^2 \right)$$

Проблема

Деревья обученные жадным алгоритмом склонны к переобучению

Регуляризация деревьев

Проблема

Деревья обученные жадным алгоритмом склонны к переобучению

Решение

Добавление различных условий на сложность дерева, редукция решающих деревьев

Определения

Пусть T — некоторое поддереву дерева T_0 . Обозначим:

- $|T|$ — количество листов в T
- $N_m = \#\{x_i \in R_m\}$
- $c_m = \frac{1}{N_m} \sum_{x_i \in R_m} y_i$
- $Q_m(T) = \frac{1}{N_m} \sum_{x_i \in R_m} (y_i - c_m)^2$

Стратегия усечения дерева

$$C_\alpha(T) = \sum_{m=1}^{|T|} N_m Q_m(T) + \alpha |T|$$

- Максимальная глубина дерева (`max_depth`)

Регуляризация деревьев в scikit-learn

- Максимальная глубина дерева (`max_depth`)
- Минимальное число наблюдений для ветвления дерева (`min_samples_split`)

- Максимальная глубина дерева (`max_depth`)
- Минимальное число наблюдений для ветвления дерева (`min_samples_split`)
- Минимальное число наблюдения в листе (`min_samples_leaf`)

- Максимальная глубина дерева (`max_depth`)
- Минимальное число наблюдений для ветвления дерева (`min_samples_split`)
- Минимальное число наблюдения в листе (`min_samples_leaf`)
- Максимальное количество признаков, используемых для деления (`max_features`)

- Максимальная глубина дерева (`max_depth`)
- Минимальное число наблюдений для ветвления дерева (`min_samples_split`)
- Минимальное число наблюдения в листе (`min_samples_leaf`)
- Максимальное количество признаков, используемых для деления (`max_features`)
- Максимальное число листьев (`max_leaf_nodes`)

- Максимальная глубина дерева (`max_depth`)
- Минимальное число наблюдений для ветвления дерева (`min_samples_split`)
- Минимальное число наблюдения в листе (`min_samples_leaf`)
- Максимальное количество признаков, используемых для деления (`max_features`)
- Максимальное число листьев (`max_leaf_nodes`)
- Минимальное изменение критерия информативности (`min_impurity_decrease`)

Основная идея

Решающие деревья не устойчивы к небольшим изменениям данных. Поэтому при обучении на различных подвыборках решающие деревья будут ошибаться на разных объектах.

Основная идея

Решащие деревья не устойчивы к небольшим изменениям данных. Поэтому при обучении на различных подвыборках решающие деревья будут ошибаться на разных объектах.

Определение

- Обучение каждого решающего дерева происходит на сгенерированной случайной подвыборке с повторениями размера обучающей выборки
- Обучение происходит на случайной подвыборке признаков (их количество — входной параметр алгоритма, для классификации берут \sqrt{n} , для регрессии $\frac{n}{3}$)
- Дерево строится до полного исчерпания подвыборки и не подвергается процедуре прунинга
- Решающее правило $a(x) = \frac{1}{T} \sum_{t=1}^T a_t(x)$

Важность признаков

- При построении случайного леса считается количество вершин, в которых используется признак с весом (количество наблюдений в вершине)

Важность признаков

- При построении случайного леса считается количество вершин, в которых используется признак с весом (количество наблюдений в вершине)
- Признак тем важнее, чем большее разница между метрикой качества на обычных данных и на данных, где этот признак случайно перемешан

Преимущества и недостатки случайного леса

Преимущества

Преимущества

- Способность эффективно обрабатывать данные с большим числом признаков и классов

Преимущества

- Способность эффективно обрабатывать данные с большим числом признаков и классов
- Нечувствительность к масштабированию значений признаков

Преимущества

- Способность эффективно обрабатывать данные с большим числом признаков и классов
- Нечувствительность к масштабированию значений признаков
- Одинаково хорошо обрабатываются как непрерывные, так и дискретные признаки

Преимущества

- Способность эффективно обрабатывать данные с большим числом признаков и классов
- Нечувствительность к масштабированию значений признаков
- Одинаково хорошо обрабатываются как непрерывные, так и дискретные признаки
- Существуют методы оценивания значимости отдельных признаков в модели

Преимущества

- Способность эффективно обрабатывать данные с большим числом признаков и классов
- Нечувствительность к масштабированию значений признаков
- Одинаково хорошо обрабатываются как непрерывные, так и дискретные признаки
- Существуют методы оценивания значимости отдельных признаков в модели
- Внутренняя оценка способности к обобщению

Преимущества и недостатки случайного леса

Преимущества

- Способность эффективно обрабатывать данные с большим числом признаков и классов
- Нечувствительность к масштабированию значений признаков
- Одинаково хорошо обрабатываются как непрерывные, так и дискретные признаки
- Существуют методы оценивания значимости отдельных признаков в модели
- Внутренняя оценка способности к обобщению
- Высокая параллелизуемость и масштабируемость

Преимущества и недостатки случайного леса

Преимущества

- Способность эффективно обрабатывать данные с большим числом признаков и классов
- Нечувствительность к масштабированию значений признаков
- Одинаково хорошо обрабатываются как непрерывные, так и дискретные признаки
- Существуют методы оценивания значимости отдельных признаков в модели
- Внутренняя оценка способности к обобщению
- Высокая параллелизуемость и масштабируемость

Недостатки

- Большой размер и сложность получающихся моделей

Преимущества и недостатки случайного леса

Преимущества

- Способность эффективно обрабатывать данные с большим числом признаков и классов
- Нечувствительность к масштабированию значений признаков
- Одинаково хорошо обрабатываются как непрерывные, так и дискретные признаки
- Существуют методы оценивания значимости отдельных признаков в модели
- Внутренняя оценка способности к обобщению
- Высокая параллелизуемость и масштабируемость

Недостатки

- Большой размер и сложность получающихся моделей
- Нулевая интерпретируемость — черный ящик

- Решающие деревья — хорошо интерпритируемый алгоритм машинного обучения

- Решающие деревья — хорошо интерпретируемый алгоритм машинного обучения
- На его основе строятся самые сильные модели машинного обучения (например, случайный лес)

На основе материалов сайта <http://www.machinelearning.ru>.